

Stable Diffusion을 활용한 그레이스케일 이미지 색칠 및 스타일 전이 통합 기법 개발

Development of an Integrated Method for Grayscale Image Colorization and Style Transfer Using Stable Diffusion

정여원

요약

디지털 이미지 복원 및 변환 기술은 사진 복원, 예술 창작 등 다양한 분야에서 중요한 역할을 하고 있다. 본 연구에서는 참조 이미지 기반의 그레이스케일 이미지 색칠 및 스타일 전이 기법을 제안한다. 우선, Adaptive Histogram Matching(AHM) 기법을 통해 그레이스케일 이미지를 참조 이미지의 색감으로 변환하고, AdaIN과 NST를 결합한 통합 모델을 사용하여 스타일 전이를 수행한다. 또한, Stable Diffusion 모델을 활용하여 사용자가 원하는 색상과 스타일을 가진 참조 이미지를 생성하고 이를 색칠 및 스타일 전이에 적용하였다. 이 연구는 이미지 변환의 정확도와 일관성을 높이며, 다양한 분야에서의 이미지 복원 및 창작 작업에 기여할 수 있을 것으로 기대된다.

그림1. pix2pix를 사용한 기존의 색칠방법



그림2. 참조이미지를 사용하는 색칠방법

사용자가 원하는 이미지를 생성할 수 있는 Stable Diffusion 기술은 색칠 기법에서 참조 이미지로 활용되어 사용자의 의도를 효과적으로 적용할 수 있다. 그림 1과 같이 기존의 색칠 기법인 pix2pix는 주어진 입력 이미지를 목표 상태(컬러 이미지)로 변환하며, 학습된 변환 규칙을 기반으로 색상을 추가한다.

이 과정에서 학습된 데이터셋에서 얻은 일반적인 색상 패턴과 스타일이 적용되며, 특정 참조 이미지를 직접 사용하는 것이 아니기 때문에 사용자가 원하는 참조 이미지의 스타일 일이나 색상을 적용하는 것은 어렵다. 따라서

1. 서론

디지털 이미지 복원 및 변환 기술은 다양한 분야에서 그 중요성이 점차 증가하고 있다. 특히, 그레이스케일 이미지를 참조 이미지의 색감과 스타일을 기반으로 효과적으로 변환하는 기술은 흑백 사진의 컬러화, 예술 작품의 복원, 그리고 창작 과정에서 사용자 경험을 크게 향상시킬 수 있다.

그러나 기존의 연구들은 참조 이미지의 색상과 스타일을 충분히 반영하지 못하거나, 사용자의 의도를 효과적으로 구현하기 어려운 한계를 가지고 있다.




그림 2와 같이 사용자가 참조 이미지를 선택하면 그 색상과 스타일을 직접 반영하는 모델을 제안한다.

본 연구에서는 그레이스케일 이미지를 참조 이미지의 색상과 스타일을 기반으로 변환하는 새로운 기법을 제안한다. 연구는 색상 정보 추출, 색칠, 스타일 전이 기법을 통합하여 고품질의 컬러화 및 스타일링 이미지를 생성하는 것을 목표로 한다.

첫째, 패션 MNIST 이미지와 다양한 스타일 및 색상의 WikiArt 이미지 데이터를 준비하였다. 참조 이미지의 색상 정보를 효과적으로 추출하기 위해 k-Means 알고리즘을 사용하여 색상 히스토그램, 컬러 모멘트, 도미넌트 컬러, 컬러 팔레트를 분석하였다. 이후, 추출된 주요 색상 정보를 바탕으로 그레이스케일 이미지를 색칠하고, 이를 BGR에서 RGB로 변환하여 시각화하였다.

둘째, 스타일 전이를 구현하기 위해 사전 훈련된 VGG19 모델을 활용한 Neural Style Transfer(NST) 기법과 AdaIN(Adaptive Instance Normalization) 기법을 결합한 통합 모델을 구축하였다. VGG19 모델은 원본 이미지와 참조 이미지의 특징을 추출하여 스타일 전이를 수행하며, AdaIN 기법은 인코더와 디코더 네트워크를 통해 스타일과 콘텐츠 간의 조화로운 이미지를 생성한다.

셋째, 스타일 전이 모델의 성능을 최적화하고 평가하기 위해 Delta E 색채 정확도 및 Perceptual Loss를 주요 지표로 활용하였다. 이 과정에서 K-Means 알고리즘 대신 AHM(Adaptive Histogram Matching) 기법을 적용하여 색상화 모델의 정확도를 더욱 높였다. 또한, AdaIN과 NST 기법을 결합한 통합 모델의 하이퍼파라미터를 최적화하여 스타일 전이 성능을 개선하였다.

마지막으로, Stable Diffusion 모델을 활용하여 사용자가 원하는 참조 이미지를 생성하고, 이를 통해 색칠 및 스타일 전이 작업을 수행하였다. 최종적으로, 원본 그레이스케일 이미지, 생성된 참조 이미지, 그리고 스타일 전이 결과물을 비교 시각화하여 연구의 성과를 명확히 제시하였다.

2. 관련 연구

2.1 그레이스케일 이미지 색칠

그레이스케일 이미지를 컬러 이미지로 변환하는 색칠 기법은 이미지 처리와 컴퓨터 비전 분야에서 오랫동안 연구되어 왔다. 초기에는 수동으로 색상을 지정하거나 간단한 규칙 기반 알고리즘을 사용하여 색칠을 수행하였으나, 최근에는 딥러닝 기반의 자동화된 기법들이 주목받고 있다.

본 연구에서는 그레이스케일 이미지의 색상화를 위해 k-Means 알고리즘을 사용하여 주요 색상을 추출한 후, Adaptive Histogram Matching(AHM) 기법을 통해 참조 이미지의 색감을 그레이스케일 이미지에 적용하는 방법을 제안하였다.

우선, 패션 MNIST 이미지와 WikiArt 이미지 데이터를 준비한 후, k-Means 알고리즘을 통해 참조 이미지의 주요 색상 정보를 추출하였다. 이 과정에서 추출된 색상 정보는 그레이스케일 이미지를 색칠하는 데 사용되며, 색칠된 이미지는 Delta E 색채 정확도를 평가 지표로 활용하여 성능을 측정한다.

그 이후, AHM 기법을 사용하여 참조 이미지의 색상 히스토그램을 그레이스케일 이미지에 매칭함으로써 더욱 정교한 색상 변환을

수행하였다. AHM은 이미지의 색상 분포를 일치시키는 방식으로, 원본 이미지와 참조 이미지의 색감 차이를 줄여주는 역할을 한다. 코드 구현에서는 OpenCV와 scikit-image 라이브러리를 사용하여 이 과정을 자동화하였으며, 변환된 이미지는 원본 이미지와 함께 시각화되고, 이후의 스타일 전이 작업에 사용된다. 이를 통해 생성된 색칠된 이미지는 정확한 색상 변환과 높은 Delta E 정확도를 나타내며, 이후의 스타일 전이 작업의 기초가 된다. 본 연구에서는 이와 같은 방식을 통해 그레이스케일 이미지를 참조 이미지의 색감으로 효과적으로 변환하는 데 성공하였다.

2.2 스타일 전이

스타일 전이(Style Transfer)는 원본 이미지의 구조를 유지하면서 참조 이미지의 스타일을 적용하는 기술로, 예술 창작 및 이미지 변환 작업에 광범위하게 사용되고 있다. 본 연구에서는 Neural Style Transfer (NST) 과 Adaptive Instance Normalization (AdaIN)를 결합한 통합 스타일 전이 모델을 구축하여 그레이스케일 이미지를 참조 이미지의 스타일로 변환하였다.

AdaIN 기법은 콘텐츠 이미지의 특징을 참조 이미지의 통계적 특징(평균 및 표준편차)으로 변환하여 스타일을 적용하는 방식이다. 이를 위해 사전 훈련된 VGG19 네트워크를 사용하였으며, VGG19의 중간 계층에서 추출된 특징 맵을 활용해 스타일 전이를 수행하였다. AdaIN은 스타일 전이의 첫 단계로, 콘텐츠 이미지의 구조를 보존하면서 참조 이미지의 스타일을 자연스럽게 적용한다.

그 다음 단계에서는 Neural Style Transfer(NST)를 적용하여 AdaIN으로 얻은 이미지를 추가적으로 최적화하였다. NST는 콘텐츠 이미지의 구조와 참조 이미지의 스타일 간의 균형을 맞추는 방식으로, 최종 이미

지의 세밀한 스타일 적용을 수행한다. 이 과정에서 PyTorch를 활용한 MSELoss 함수를 사용하여 콘텐츠와 스타일 간의 차이를 최소화하였다. 또한, 최적화된 하이퍼파라미터(alpha, style_weight, content_weight)를 적용하여 스타일 전이의 품질을 극대화하였다.

이와 같은 통합 접근법을 통해 원본 그레이스케일 이미지에 참조 이미지의 스타일을 적용한 최종 스타일링 이미지를 생성하였으며, 이 과정에서 각기 다른 스타일의 WikiArt 이미지를 참조 이미지로 사용하여 다양한 스타일 변환을 수행하였다.

2.3 Stable Diffusion 기반 이미지 생성

Stable Diffusion은 이미지 생성 및 변환에서 높은 정밀도와 성능을 제공하는 최신 확산 모델(Diffusion Model) 중 하나이다. 본 연구에서는 Stable Diffusion 모델을 사용하여 참조 이미지를 생성하고, 이를 바탕으로 그레이스케일 이미지를 색칠하고 스타일을 전이하는 과정을 수행하였다.

우선, Hugging Face의 Diffusers 라이브러리를 활용하여 Stable Diffusion 모델을 구현하였다. 사용자는 특정 텍스트 프롬프트를 입력하여 원하는 스타일의 참조 이미지를 생성할 수 있으며, 본 연구에서는 "A beautiful painting in the style of Van Gogh"와 같은 프롬프트를 사용하여 예술적 스타일의 참조 이미지를 생성하였다. 생성된 이미지는 이후 색칠 및 스타일 전이 작업의 참조 이미지로 활용되었다.

생성된 참조 이미지는 Adaptive Histogram Matching(AHM) 기법을 통해 그레이스케일 이미지의 색칠에 사용되었다. AHM 기법은 참조 이미지의 색상 히스토그램을 그레이스케일 이미지에 매칭하여, 원본 이미지의 색상을 참조 이미지의 색감으로 변환하는 데 효

과적이다. 이를 통해 색칠된 이미지는 보다 자연스러운 색감을 가지게 되며, 이후 스타일 전이 작업에 활용된다.

마지막으로, 색칠된 이미지를 대상으로 앞서 개발된 AdaIN 및 NST 통합 모델을 적용하여 최종 스타일링 이미지를 생성하였다. 이 과정에서 참조 이미지와 색칠된 이미지의 스타일이 조화롭게 결합되도록 최적화된 알고리즘을 사용하였다. 최종 결과물은 원본 그레이스케일 이미지, Stable Diffusion을 통해 생성된 참조 이미지, 그리고 스타일 전이 결과물을 함께 시각화하여 연구의 성과를 명확히 제시하였다.

3. 연구 방법

본 연구는 크게 그레이스케일 이미지 색칠, 스타일 전이, 그리고 Stable Diffusion을 활용한 참조 이미지 생성 및 적용으로 구성된다.

3.1 그레이스케일 이미지 색칠

그레이스케일 이미지를 컬러화하기 위해, 본 연구에서는 초기 단계에서 k-Means 알고리즘을 사용하여 참조 이미지의 주요 색상 정보를 추출하였다. k-Means는 이미지의 색상 클러스터링을 통해 주요 색상을 도출하는데, 이를 통해 그레이스케일 이미지의 초기 색칠을 수행하였다. 또한, 이 과정에서 하이퍼파라미터 최적화 기법을 적용하여, Delta E 색채 정확도를 최대한 낮추는 방향으로 k-Means의 성능을 개선하려고 하였다.

그러나 k-Means 알고리즘의 한계로 인해, 색상화된 이미지의 Delta E 값이 충분히 낮아지지 않았으며, 색상 변환의 정확도를 높이기 위해 추가적인 개선이 필요했다. 이에 따라 본 연구에서는 Delta E 값을 더욱 줄이기 위

해 기존의 k-Means 알고리즘 대신 다른 기법을 탐색하였다.

색칠 모델의 최적화를 위해, 본 연구에서는 Reinhard의 Color Transfer 알고리즘, Luminance Preserving 기법, 그리고 Adaptive Histogram Matching(AHM) 기법을 비교하였다.

Reinhard의 Color Transfer 알고리즘은 참조 이미지와 대상 이미지 간의 색상 정보를 평균과 표준편차를 기준으로 매칭하여 색상을 전송하는 방식으로, 색상 간의 전역적인 유사성을 유지하는 데 초점을 맞춘다. 이 방법은 전체적인 색감 조정을 통해 자연스러운 색상 전환을 가능하게 한다.

Luminance Preserving 기법은 밝기 정보를 유지하면서 색상을 전송하는 방식으로, 이미지의 명암 대비를 유지하면서도 색상 변화를 적용할 수 있게 한다. 이는 이미지의 원래 조명 조건을 보존하면서도 색상을 변환할 수 있는 장점이 있다.

다양한 기법을 적용한 결과, Delta E 값을 가장 낮게 유지할 수 있는 방법으로 AHM 기법이 선정되었다. AHM은 참조 이미지의 색상 히스토그램을 그레이스케일 이미지에 매칭하여, 보다 정밀한 색상 변환을 가능하게 한다.

3.2 스타일 전이

그레이스케일 이미지에 색상이 적용된 후, 스타일 전이를 통해 참조 이미지의 스타일을 변환된 이미지에 적용하였다. 본 연구에서는 Adaptive Instance Normalization(AdaIN)과 Neural Style Transfer(NST)를 결합한 통합 모델을 구축하였다. 이 통합 모델은 두 기법의 장점을 결합하여 보다 자연스럽고 일관된 스타일 전이 결과를 도출하는 것을 목표로

한다.

먼저, 사전 훈련된 VGG19 모델을 사용하여 콘텐츠 이미지와 참조 이미지의 특징 맵을 추출한다. VGG19는 이미지를 여러 레이어로 분해하여, 이미지의 고수준 특징(예: 텍스처, 패턴)을 추출하는 데 유용하다. AdaIN 기법은 콘텐츠 이미지의 특징 맵을 참조 이미지의 스타일 통계(평균과 표준편차)로 조정하여 초기 스타일 전이를 수행한다. 이 과정에서, 콘텐츠 이미지의 구조는 유지되면서도 참조 이미지의 스타일이 자연스럽게 적용된다.

구체적으로, AdaIN은 콘텐츠 이미지의 특징 맵에서 평균과 표준편차를 제거하고, 이를 참조 이미지의 평균과 표준편차로 대체하여 새로운 특징 맵을 생성한다. 이 새로운 특징 맵은 스타일이 반영된 상태로 디코더에 입력된다.

AdaIN으로 전이된 이미지는 기본적으로 스타일 전이의 초기 결과를 제공하지만, 이를 더욱 세밀하게 다듬기 위해 Neural Style Transfer(NST) 기법이 적용된다. NST는 콘텐츠 이미지와 참조 이미지의 특징 맵 간의 차이를 최소화하는 방식으로 동작하며, 이를 위해 PyTorch의 MSELoss 함수를 사용하여 콘텐츠 손실과 스타일 손실을 계산한다.

이렇게 AdaIN과 NST 기법이 결합된 통합 모델은 최종 스타일링 이미지를 생성한다. 이 이미지에는 참조 이미지의 스타일이 효과적으로 전이되면서도, 콘텐츠 이미지의 구조적 일관성이 유지된다.

3.3 Stable Diffusion 기반 참조 이미지 생성 및 적용

Stable Diffusion 모델은 사용자가 원하는 스타일의 참조 이미지를 생성하는 데 활용되

었다. Hugging Face의 Diffusers 라이브러리를 사용하여 Stable Diffusion 모델을 구현하였으며, 특정 텍스트 프롬프트를 입력하여 참조 이미지를 생성하였다. 예를 들어, "A beautiful painting in the style of Van Gogh"라는 프롬프트를 활용하여 사용자가 원하는 예술적 스타일의 참조 이미지를 생성하였다.

생성된 참조 이미지는 이후의 색칠 및 스타일 전이 작업에 중요한 입력으로 사용된다. 먼저, 참조 이미지는 AHM 기법을 통해 그레이스케일 이미지의 색칠에 적용된다. 이 과정에서 참조 이미지의 색상 분포를 그레이스케일 이미지에 적용하여 자연스러운 색감이 구현된다.

그 다음, 색칠된 이미지를 대상으로 AdaIN과 NST를 결합한 통합 모델을 적용하여 최종 스타일링 이미지를 생성하였다. 최종 결과물은 원본 그레이스케일 이미지, Stable Diffusion을 통해 생성된 참조 이미지, 그리고 스타일 전이 결과물을 함께 시각화하여 연구의 성과를 명확히 제시하였다.

4. 실험

4.1 데이터 셋

본 연구에서는 흑백 이미지로 패션 MNIST 데이터셋을 사용하였으며, 참조 이미지로는 WikiArt 데이터셋을 사용하였다. 각 데이터셋의 특징과 본 연구에서 이들을 사용한 이유를 아래와 같이 설명한다.

패션 MNIST(Fashion MNIST)는 의류 및 패션 아이템으로 구성된 대규모 흑백 이미지 데이터셋이다. 이 데이터셋은 총 10개의 클래스(티셔츠/탑, 바지, 풀오버, 드레스, 코트, 샌

들, 셔츠, 스니커즈, 가방, 앵클 부츠)로 구성되어 있으며, 각 클래스는 28x28 픽셀 크기의 흑백 이미지로 표현된다. 패션 MNIST는 컴퓨터 비전 및 이미지 처리 분야에서 매우 널리 사용되며, 특히 이미지 분류, 객체 탐지, 이미지 변환 등의 다양한 연구에 활용되고 있다.

본 연구에서 패션 MNIST를 사용하는 이유는 다음과 같다. 패션 MNIST는 단순한 구조의 흑백 이미지로 구성되어 있어, 색칠 및 스타일 전이 기법을 적용하기에 적합한 데이터셋이다. 또한 데이터셋이 10개의 명확한 카테고리로 구분되어 있어, 각 카테고리별로 참조 이미지와의 색상 및 스타일 전이 실험을 체계적으로 수행할 수 있다. 마지막으로 널리 사용되는 데이터셋이기 때문에, 연구 결과를 다른 연구와 비교하거나 재현할 때 유리하다.

WikiArt 데이터셋은 예술 작품의 이미지로 구성된 대규모 컬러 이미지 데이터셋이다. 이 데이터셋에는 다양한 시대와 스타일에 걸친 예술 작품들이 포함되어 있으며, 그림, 조각, 설치미술 등 다양한 예술적 표현이 담겨 있다. WikiArt 데이터셋은 다양한 예술적 스타일과 색상을 포함하고 있어, 이미지 색칠 및 스타일 전이와 같은 연구에 매우 적합하다.

본 연구에서 WikiArt를 참조 이미지로 사용하는 이유는 다음과 같다. WikiArt 데이터셋은 다양한 색상 팔레트와 예술적 스타일을 포함하고 있어, 흑백 이미지에 색을 입히고 스타일을 전이하는 작업에 풍부한 참조 데이터를 제공한다. 또한 다양한 예술적 스타일을 표현하는 이미지를 사용함으로써, 본 연구에서 제안한 방법이 다양한 스타일에 대해 어떻게 반응하는지를 분석할 수 있다.



그림3. Wikiart 데이터셋의 예

4.2 평가 지표

본 연구에서는 그레이스케일 이미지의 색칠 및 스타일 전이 기법의 성능을 평가하기 위해 Delta E와 Perceptual Loss 이 두 가지 주요 평가지표를 사용하였다. 이들 지표는 각각 색상 변환의 정확도와 스타일 전이의 품질을 정량적으로 평가하는 데 사용된다.

본 연구에서는 CE21000이라는 컬러 정확도 평가를 위해 Delta E를 계산하였다. CE21000은 색상 차이를 보다 정밀하게 측정하기 위해 다양한 색상 공간에서의 색상 차이를 분석하는 방법론을 포함하며, Delta E는 그 핵심 요소로 사용된다.

Delta E는 색상 차이를 정량적으로 평가하는 지표로, 두 색상 간의 인지적 차이를 수치화하여 표현한다. Delta E 값이 낮을수록 두 색상 간의 차이가 적으며, 색상 변환의 정확도가 높음을 의미한다. 이 지표는 주로 그레이스케일 이미지가 참조 이미지의 색상과 얼마나 잘 일치하는지를 평가하는 데 사용된다.

본 연구에서는 다양한 색칠 기법을 비교하기 위해 Delta E를 주요 지표로 사용하였다. 특히, Delta E 값을 줄이기 위해 k-Means 알고리즘의 하이퍼파라미터 최적화부터 시작하여,

최종적으로 AHM (Adaptive Histogram Matching) 기법을 도입하였다. AHM 기법이 가장 낮은 Delta E 값을 기록하며 최종적으로 색칠 모델로 선정되었다.

Perceptual Loss는 스타일 전이 기법의 성능을 평가하기 위해 사용되는 지표로, 변환된 이미지와 참조 이미지 간의 인지적 유사성을 측정한다. 이는 단순한 픽셀 차이가 아닌, 이미지의 고수준 특징(예: 질감, 색상 패턴, 스타일 등)이 얼마나 잘 일치하는지를 평가하는 방법이다. Perceptual Loss는 주로 사전 훈련된 신경망(VGG19 등)의 특정 계층에서 추출된 특징 맵을 비교함으로써 계산된다.

본 연구에서는 Neural Style Transfer (NST)와 Adaptive Instance Normalization (AdaIN) 기법을 결합한 통합 모델을 평가하기 위해 Perceptual Loss를 사용하였다. 스타일 전이 과정에서 참조 이미지의 스타일이 얼마나 자연스럽게 적용되었는지를 평가하기 위해, Perceptual Loss를 주요 지표로 삼았다. 이 지표는 특히, 스타일 전이 결과물의 품질이 높고, 원본 이미지의 콘텐츠를 유지하면서도 참조 이미지의 스타일을 효과적으로 반영하는지를 평가하는 데 유용하다.

4.3 실험 과정

본 연구의 실험 과정은 크게 그레이스케일 이미지의 색칠 모델 최적화와 스타일 전이 모델 최적화 두 단계로 나누어 수행되었다.

첫 단계에서는 k-Means 알고리즘을 사용하여 그레이스케일 이미지를 색칠하였으며, 이 알고리즘의 성능을 극대화하기 위해 랜덤 서치(Random Search)를 통해 하이퍼파라미터 k와 초기화 횟수 n_init 을 최적화하였다. 최적화된 하이퍼파라미터는 Delta E 값을 최소화하도록 설정되었으나, k-Means 알고리즘만으

로는 Delta E 값을 충분히 낮추는 데 한계가 있었다.

이에 따라, 기존의 k-Means 기반 색칠 모델을 대체하기 위해 다른 색칠 기법들을 실험하였다. Reinhard의 Color Transfer 알고리즘, Luminance Preserving 기법, 그리고 AHM (Adaptive Histogram Matching) 기법을 적용한 후, Delta E 값을 비교하였다. 이 중 AHM 기법이 가장 낮은 Delta E 값을 기록하였고, 따라서 최종적으로 AHM 기법을 색칠 모델로 선정하였다.

두 번째 단계에서는 AdaIN과 NST를 결합한 통합 스타일 전이 모델의 성능을 최적화하였다. 이를 위해 랜덤 서치(Random Search) 기법을 사용하여 Alpha, Content Weight, Style Weight, Num Epochs 등의 하이퍼파라미터를 조정하여 최종 스타일 전이 결과가 원하는 대로 나오도록 최적화한다. Alpha는 AdaIN과 NST 결과 간의 조합 비율을 조정하며, Content Weight와 Style Weight는 콘텐츠와 스타일 간의 균형을 맞추는 데 사용된다.

랜덤 서치를 통해 최적의 하이퍼파라미터를 선정하는 과정에서, 최종 성능 평가를 위해 Content Loss와 Style Loss를 각각 계산하였다. Content Loss는 전이된 이미지가 원본 콘텐츠 이미지의 구조를 얼마나 잘 유지하고 있는지를 측정하며, Style Loss는 전이된 이미지가 참조 스타일 이미지를 얼마나 잘 반영하고 있는지를 평가한다. 이러한 Loss를 통해 콘텐츠와 스타일 간의 균형을 평가하며, 두 값을 더한 Total Loss를 최종 성능 지표로 사용하였다.

Perceptual Loss의 개선이 멈추는 시점에 조기 종료를 적용하여, 불필요한 학습 시간을 줄이고 최적의 모델을 확보하였다. 최적화된

스타일 전이 모델은 참조 이미지의 스타일을 콘텐츠 이미지에 효과적으로 전이하면서도, 콘텐츠 이미지의 본래 구조를 유지하는 데 성공하였다.

5. 실험 결과

5.1 K-Means 알고리즘 최적화 실험 과정

하이퍼 파라미터(K, n_init) 조합 최적화를 위해 랜덤 서치 수행. 3-Fold 교차 검증을 통해 다양한 파라미터 조합을 테스트 함.

실험 횟수	n_clusters(K)	n_init	실험 시간
1	10	13	1.6min
2	10	13	1.9min
3	10	13	1.4min
4	2	16	23.6s
5	2	16	20.9s
6	2	16	18.3s
7	10	15	2.0min
8	10	15	1.8min
9	10	15	1.6min
10	8	9	51.5s
11	8	9	58.0s
12	8	9	48.5s
13	8	5	34.5s
14	8	5	32.3s
15	8	5	33.6s
16	5	15	56.7s
17	5	15	52.9s
18	5	15	1.0min
19	3	10	18.3s
20	3	10	21.0s
21	3	10	20.4s
22	10	5	35.5s
23	10	5	37.4s
24	10	5	32.4s
25	6	13	58.9s
26	6	13	55.3s
27	6	20	50.2s
28	5	13	1.2min
29	5	20	1.1min
30	5	20	1.2min

실험 결과 최적의 파라미터 조합은 n_cluster(k) : 10, n_init: 13으로 찾아졌다.

5.2 다양한 색칠 기법 비교 결과

색칠 기법	Average CIEDE2000 ΔE
K-Means (최적화된 파라미터)	37.62
Reinhard의 Color Transfer	24.41
Luminance Preserving	26.03
Adaptive Histogram Matching (AHM)	20.58

실험 결과 AHM 기법이 가장 낮은 Delta E 값을 기록하며, 최적의 색칠 성능을 보였다.

5.3 스타일 전이 모델 성능 결과

AdaIN과 NST 통합 모델의 성능 최적화를 위해 랜덤 서치(Random Search)를 사용하여 하이퍼파라미터, Alpha, content_weight, style_weight, num_epochs 의 조합을 탐색하였다. 최종 손실값(Total Loss)을 기준으로 각 실험의 성능을 평가하였다.

실험 횟수	Alpha	Content_weight	Style_weight	Num_epochs	최종 content loss	최종 style loss
1	0.3161	4.2797	735.5033	171	0.8144	0.1165
2	0.8535	1.9800	628.8659	298	0.5538	0.1243
3	0.1264	7.4723	288.4371	282	0.9840	0.1239
4	0.5841	2.6891	712.6156	206	0.6112	0.1129
5	0.696	9.5160	875.8643	155	0.5670	0.1121

	6					
6	0.8 1 7 5	1.3851	176. 0438	294	0.5527	0.1206
7	0.5 2 3 8	2.6485	150. 1600	207	0.7192	0.1141
8	0.0 4 8 0	1.3695	221. 7890	131	1.0537	0.1234
9	0.3 9 6 9	2.1769	700. 2994	190	0.7389	0.1140
10	0.5 0 4 6	9.0706	113. 7888	128	0.6631	0.1152

실험 결과 Alpha: 0.4238, Content Weight: 2.6485, Style Weight: 150.1600, Num Epochs: 207이 최적의 파라미터 조합으로 선정 되었다. 이 조합에서의 최종 Content Loss는 0.7192, Style Loss는 0.1141로 평가 되었다.

6. 최종 결과 및 시각화


최적화 된 색칠 및 스타일 전이를 수행한 결과를 시각화 하고 분석한다. 또한, Stable Diffusion 모델을 활용하여 생성된 참조 이미지를 바탕으로 색칠 및 스타일 전이된 결과 도 함께 제시한다. 패션 mnsit의 10개 클래스에서 각각 1장씩 입력 이미지로 선택되고 WikiArt 데이터셋 또한 참조 이미지로서 10장이 선택되었다.


6.1 패션MNIST 이미지 색칠 및 스타일 전이

각 패션MNIST 이미지는 WikiArt 이미지(1번부터 10번까지)와 결합하여 다음과 같은 단계로 처리되었다.

AHM을 통한 색상 전송: 패션MNIST의 흑백 이미지를 WikiArt 데이터셋의 1번부터 10번까지의 컬러 이미지를 참조하여 Adaptive Histogram Matching(AHM) 기법을 사용해 색상을 전송하였다. AHM은 참조 이미지의 색상 분포를 흑백 이미지에 적용하여 자연스러운 색감을 구현할 수 있게 한다.

스타일 전이: AHM을 통해 색칠된 이미지를 바탕으로, WikiArt 데이터셋의 1번부터 10번까지의 참조 이미지를 활용하여 사전 훈련된 VGG19 모델을 사용해 스타일 전이를 수행하였다. 이 과정에서는 AdaIN과 NST를 결합한 통합 모델을 사용하였으며, 최적화된 하이퍼파라미터를 적용하여 참조 이미지의 스타일을 콘텐츠 이미지에 자연스럽게 반영하였다.





6.2 Stable Diffusion을 활용한 색칠 및 스타일 전이

Stable Diffusion 모델을 활용하여 참조 이미지를 생성하고, 이를 기반으로 AHM과 스타일 전이 기법을 적용한 결과를 그림 4에 제시하였다. 이 예제는 "Ankle Boot" 클래스를 대상으로 하였으며, Stable Diffusion을 통해 생성된 Van Gogh 스타일의 참조 이미지를 사용하였다.



그림4. Stbale Diffusion을 활용한 색칠

6.3 결론

본 연구에서는 그레이스케일 이미지를 참조 이미지의 색상과 스타일로 변환하는 새로운 방법론을 제시하였다. 패션MNIST 데이터셋의 흑백 이미지와 WikiArt 데이터셋의 컬러 이미지를 활용하여, Adaptive Histogram Matching(AHM) 기법을 통해 효과적인 색상 전송을 수행하였고, 이어서 AdaIN과 NST를 결합한 통합 스타일 전이 모델을 사용해 참조 이미지의 스타일을 반영한 최종 이미지를 생성하였다.

색상 전송 단계에서는 기존의 KMeans 알고리즘을 AHM 기법으로 대체하여 색상 정확도를 크게 향상시켰으며, 그 결과 델타 E 값이 현저히 감소하여 실제 색상과의 유사도를 개선하였다. 또한, 스타일 전이 단계에서는 최적화된 하이퍼파라미터를 적용하여, 참조 이미지의 스타일을 콘텐츠 이미지에 자연스럽게 적용할 수 있었다.

최종적으로, 패션MNIST 데이터셋의 10개 이미지와 WikiArt 데이터셋의 10개 참조 이미지를 활용한 실험을 통해 제안한 방법론의 우수성을 입증하였다. 생성된 이미지는 참조

이미지의 색상과 스타일을 효과적으로 반영하여, 다양한 예술적 창작 작업에 응용 가능성을 보여주었다.

본 연구의 결과는 향후 디지털 이미지 복원 및 창작 분야에서 활용될 수 있으며, 특히 흑백 사진의 복원, 예술 작품의 재창조, 교육 자료 제작 등 다양한 응용 분야에서 혁신적인 기여를 할 수 있을 것으로 기대된다. 추가적으로, 제안한 방법론은 다른 이미지 도메인으로의 확장 가능성이 있으며, 이를 위한 다양한 참조 이미지 데이터셋을 통한 실험이 후속 연구로 제안될 수 있다.

Applications, 21(5), 34-41.

- [4] Rombach, R., Blattmann, A., Lorenz, D., Esser, P., & Ommer, B. (2022). High-Resolution Image Synthesis with Latent Diffusion Models. *In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 10684-10695.

■ 참고문헌

- [1] Gatys, L. A., Ecker, A. S., & Bethge, M. (2016). Image style transfer using convolutional neural networks. *In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2414-2423.
- [2] Huang, X., & Belongie, S. (2017). Arbitrary Style Transfer in Real-Time with Adaptive Instance Normalization. *In Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 1501-1510.
- [3] Reinhard, E., Adhikhmin, M., Gooch, B., & Shirley, P. (2001). Color transfer between images. *IEEE Computer Graphics and*

성신여대 AI학과

정여원



지도교수 변혜원



